

Text-to-Music

*Sinh nhạc nền cho trò chơi
từ mô tả văn bản*



BÁO CÁO THUYẾT TRÌNH

So sánh hai họ mô hình: **Music Transformer** vs **Diffusion Model**

Cùng dataset, cùng prompt, cùng bộ metric - Trả lời câu hỏi: mô hình nào phù hợp hơn cho nhạc nền game?

LĨNH VỰC

Generative AI - Music Generation
Conditional Sequence Generation

FRAMEWORK và DỮ LIỆU

PyTorch + MIDI (~14k bản nhạc),
MAESTRO, MidiCaps, ComMU,
VGMIDI

Giới thiệu thành viên

Năm thành viên của nhóm 04

04

I.

THÀNH VIÊN

Trần Bá Đạt

MSSV: 20252129M

II.

THÀNH VIÊN

Phạm Tuấn Anh

MSSV: 20252251M

III.

THÀNH VIÊN

**Nguyễn Khánh
Trường Lộc**

MSSV: 20252124M

IV.

THÀNH VIÊN

Phạm Đàm Quân

MSSV: 20252609M

V.

THÀNH VIÊN

Vũ Đức Minh

MSSV: 20252252M

Nội dung buổi thuyết trình

Bốn phần: Bài toán, dữ liệu, mô hình và kết quả so sánh.

I.

Bài toán & Bối cảnh

Text-to-Music là gì, khác Music Generation ra sao, vì sao phù hợp với Generative AI, và ứng dụng trong game development.

II.

Dữ liệu & Tiền xử lý

~14k bản MIDI từ 4 nguồn, chuẩn hóa về 6 thuộc tính (mood, genre, scene, tempo, instrument, energy), chia train/val cố định.

III.

Hai mô hình

Music Transformer (autoregressive, REMI tokens) và Diffusion Model (piano-roll 2D + CFG)

IV.

Đánh giá & So sánh

Metric, thời gian train + infer, trả lời câu hỏi: *mô hình nào phù hợp hơn?*

Text-to-Music là gì?

Bài toán sinh nhạc từ mô tả văn bản, thuộc nhóm Conditional Sequence Generation, một dạng bài toán liên phương thức (cross-modal) giữa ngôn ngữ và âm nhạc.



ĐIỂM KHÁC BIỆT

MUSIC GENERATION

Mô hình tự quyết định
Người dùng không kiểm soát mood, tempo, nhạc cụ.
→ ứng dụng: sáng tác tự do

TEXT-TO-MUSIC

Người dùng kiểm soát chi tiết
Mô tả nhạc theo cảm xúc, nhịp điệu, v.v và nhạc sinh theo đúng yêu cầu.
→ ứng dụng: nhạc nền game, phim, quảng cáo

Vì sao bài toán này phù hợp với Generative AI?

i.

Bản chất sáng tạo

Với prompt “happy fantasy village” có vô số bản nhạc hợp lệ.
Phù hợp với Generative AI: học phân phối dữ liệu rồi tạo các nội dung mới.

ii.

Cấu trúc phân cấp rõ ràng

Âm nhạc là dữ liệu tuần tự với cấu trúc phân cấp (note → beat → measure). Phù hợp cho Transformer, RNN hoặc Diffusion Model.

iii.

Dữ liệu phong phú

Hàng triệu file MIDI công khai, đủ dữ liệu cho huấn luyện các mô hình sinh cỡ vừa.

iv.

Nhu cầu thực tế

Indie developer thiếu ngân sách nhạc sĩ; Studio cần prototype nhanh; Nhu cầu nhạc miễn phí bản quyền.

Các loại model hỗ trợ sinh nhạc

Bảng khảo sát các mô hình sinh nhạc, dựa trên chất lượng, tài nguyên huấn luyện và khả năng tự triển khai.

Mô hình	Ý tưởng cốt lõi	Chất lượng	GPU cần	Tự triển khai
Transformer (vanilla)	Self-attention, coi MIDI là chuỗi tokens	★★★★☆☆	1× RTX 3090	★★★★★★
Music Transformer ★	Relative Positional Encoding, học long-range dependencies và các cấu trúc lặp của nhạc	★★★★★☆☆	1× RTX 3090	★★★★★☆☆
MuseNet (OpenAI)	GPT-2 với sparse attention để sinh nhạc đa nhạc cụ và các tác phẩm dài.	★★★★★★★	4–8× V100	★★★☆☆☆☆
MusicLM (Google)	Sinh nhạc theo kiến trúc phân cấp, chuyển từ mô tả văn bản sang biểu diễn ngữ nghĩa rồi đến âm thanh.	★★★★★★★	TPU pod	★★☆☆☆☆☆
AudioLDM / Stable Audio	Sinh âm thanh bằng Latent Diffusion trên không gian latent của spectrogram.	★★★★★☆☆	2–4× A100	★★★☆☆☆☆
Diffusion cho MIDI ★	Áp dụng Diffusion để khử nhiễu dần trên biểu diễn MIDI (piano-roll), xem bản nhạc như dữ liệu hai chiều.	★★★★★☆☆	1–2× RTX 3090	★★★★☆☆☆
VAE / GAN	Autoencoder / adversarial cho MIDI	★★★☆☆☆☆	1× RTX 3060+	★★★☆☆☆☆

★ LỰA CHỌN

Music Transformer và Diffusion piano-roll, hai họ mô hình khác nhau, cùng phân khúc GPU vừa phải, có khả năng tự xây dựng và so sánh song song.

Hai cách kể chuyện, cùng một bản nhạc

Cả hai đều đại diện cho hai họ mô hình sinh khác nhau trong Generative AI.

A · AUTOREGRESSIVE

Music Transformer

Coi bản nhạc như một câu văn dài và sinh từng note một, mỗi note đoán từ những note trước đó.

- ♪ Biểu diễn nhạc dưới dạng chuỗi REMI tokens
- ♪ Attention học được cấu trúc lặp lại (motif, hợp âm)
- ♪ Sinh tuần tự từng nốt nhạc
- ♪ Loss: Cross-entropy giữa nốt dự đoán và nốt thực tế

NGUỒN CẢM HỨNG

Huang et al. — Music Transformer (2018)
Cùng họ mô hình với GPT / ChatGPT.

B · DENOISING

Diffusion Model

Coi bản nhạc như một bức tranh 2D ($\text{pitch} \times \text{time}$), xuất phát từ nhiễu rồi khử nhiễu dần ra nhạc.

- ♪ Biểu diễn nhạc thành piano-roll 88×256
- ♪ UNet + self-attention học cách khử nhiễu
- ♪ Sinh song song toàn bộ biểu diễn âm nhạc thay vì từng note
- ♪ Loss: MSE giữa nhiễu dự đoán và nhiễu thật

NGUỒN CẢM HỨNG

Ho et al. — DDPM (2020)
Cùng họ mô hình với Stable Diffusion / Midjourney.

Dataset chung cho cả hai mô hình

Số lượng

11,144

bản nhạc MIDI đã lọc & chuẩn hóa

BỐN NGUỒN DỮ LIỆU

MAESTRO v3.0.0	Piano classical chất lượng cao - 1,276 file
MidiCaps	MIDI + caption tự do, đa dạng phong cách
ComMU ★	~11,144 MIDI có nhãn cấu trúc (mood, genre, inst) và là <i>nguồn chính</i>
VGMIDI	MIDI nhạc trò chơi kèm nhãn emotion

SÁU THUỘC TÍNH CHUẨN HÓA



Mood
happy, sad, tense, calm...



Genre
fantasy, rpg, sci-fi...



Scene
village, dungeon, battle...



Tempo
slow, medium, fast...



Instrument
piano, strings, synth...



Energy
calm, medium, high...

Luồng dữ liệu

Luồng xử lý dữ liệu gồm 4 bước



TRANSFORMER → REMI TOKENS

Bản nhạc → chuỗi token mô tả sự kiện âm nhạc

[NOTE_ON_60, VEL_80, TIME_SHIFT_100, NOTE_OFF_60, ...]


DIFFUSION → Ma trận Piano-Roll 2 chiều

Bản nhạc → ma trận 88×256 (pitch $\times$ time)

Mỗi ô trong ma trận biểu thị trạng thái có/không có nốt

Chuẩn hóa Input - Output

Hai mô hình Transformer và Diffusion đều nhận cùng định dạng prompt và được yêu cầu trả về cùng định dạng đầu ra (file MIDI).



Music Transformer

Nhạc là một câu chuyện, mỗi note được dự đoán dựa trên tất cả note đã có trước đó.

Ý TƯỞNG CỐT LÕI

Giống cách ChatGPT sinh văn bản, bản nhạc cũng được viết **từng token một**, mỗi token dựa vào những token trước:

CÔNG THỨC

$$p(\text{nhạc}) = \prod p(\text{token}_t \mid \text{token}_{<t}, \text{prompt})$$

“Xác suất của cả bản nhạc bằng tích xác suất của từng token, nếu biết prompt và các token trước”.

🎵 **Relative Position Attention:** ghi nhớ quan hệ giữa các nốt

🎵 **Cross-Attention:** kết nối prompt với nhạc đang sinh

🎵 ~7–8 triệu tham số, đủ nhẹ để train trên 1 GPU

MINH HỌA SINH TOKEN

PROMPT

happy · fantasy · village · fast · piano · medium

MÔ HÌNH DẦN DẦN DỰ ĐOÁN

t=1 → **SET_TEMPO_140**

t=2 → **NOTE_ON_60** (đô)

t=3 → **VELOCITY_80** (mạnh vừa)

t=4 → **TIME_SHIFT_120**

t=5 → **NOTE_ON_64** (mi)

t=6 → **NOTE_ON_67** (sol)

t=7 → ... hàng nghìn token nữa

Mỗi bước, mô hình dự đoán một token mới dựa trên prompt và toàn bộ chuỗi token trước đó.

Diffusion Model

Xuất phát từ nhiễu trắng, mô hình dần dần khử nhiễu cho đến khi tạo ra một bản nhạc hoàn chỉnh

Ý TƯỞNG CỐT LÕI

Giống cách một nhà điêu khắc *gọt tượng từ khối đá*, mô hình từng bước loại bỏ nhiễu để dần hình thành bản nhạc.


HAI QUÁ TRÌNH

- Forward (Huấn luyện)** → Thêm nhiễu vào bản nhạc thật.
- Reverse (Sinh nhạc)** → Khử nhiễu từng bước để tạo bản nhạc mới.

Mô hình chỉ cần học cách dự đoán phần nhiễu đã được thêm vào

- 🎵 **UNet + self-attention:** dự đoán và loại bỏ nhiễu
- 🎵 **Classifier-Free Guidance (CFG):** tăng mức độ tuân thủ prompt
- 🎵 **EMA:** giúp quá trình sinh nhạc ổn định hơn

MINH HỌA QUÁ TRÌNH KHỬ NHIỄU



t = 0 · KẾT QUẢ

Piano-roll hoàn chỉnh
→ **Chuyển đổi thành file MIDI**

Quá trình sinh nhạc diễn ra qua khoảng 50 - 80 bước khử nhiễu.

Huấn luyện hai mô hình

Hai mô hình được huấn luyện trên cùng phần cứng và đánh giá tại các mốc epoch 1, 5 và 10.

PHẦN CỨNG · GPU THỬ NGHIỆM

LAPTOP / DESKTOP PHỔ THÔNG

RTX 4060 / 5060

8 GB VRAM - cấu hình tối thiểu cho thí nghiệm
bs=8 (Transformer), bs=2–4 (Diffusion)

LỰA CHỌN CHÍNH ★

RTX 5060 Ti

16 GB VRAM - hỗ trợ batch size lớn và chuỗi dài
bs=16 (Transformer), bs=8 (Diffusion)

FRAMEWORK & PHẦN MỀM

PyTorch + AMP

AdamW · Mixed Precision (AMP) · Gradient Accumulation → *tiết kiệm VRAM đáng kể*

CẤU HÌNH HUẤN LUYỆN · TRANSFORMER

♪ Khoảng **7 - 8 triệu** tham số, sequence length = 1024

♪ Loss: **Cross-Entropy** trên token tiếp theo

♪ Lưu checkpoint tại các mốc epoch **1, 5, 10, 20, 30**

♪ Thời gian huấn luyện: khoảng 2 - 5 phút/epoch (RTX 4060)

♪ Huấn luyện trong **30 epoch**, không sử dụng Early Stopping.

CẤU HÌNH HUẤN LUYỆN · DIFFUSION

♪ Đầu vào: Piano-roll **88 × 256 @ 24 Hz** (~10,6 giây)

♪ Loss: **MSE** giữa nhiễu dự đoán và nhiễu thật

♪ Cosine Noise Schedule + CFG (drop rate = 10%) + EMA (0.999)

♪ Thời gian huấn luyện: khoảng 3 - 8 phút/epoch (RTX 4060)

♪ Huấn luyện trong 30 epoch.

Phương pháp đánh giá

Không so sánh trực tiếp giá trị loss (do $Cross-Entropy \neq MSE$); thay vào đó đánh giá dựa trên các bản nhạc MIDI được sinh ra.

A · CHẤT LƯỢNG BẢN NHẠC

Note density

Mật độ nốt nhạc (số nốt/giây).

Silence ratio

Tỷ lệ khoảng lặng trong bản nhạc.

Polyphony mean

Số nốt trung bình được phát đồng thời (mức độ đa âm)

Pitch range & mean

Dải cao độ và cao độ trung bình của bản nhạc (mức độ thanh, trầm)

Instrument match ★ quan trọng

Nhạc cụ sinh ra có đúng prompt yêu cầu không?

Pitch-class JS divergence

Khoảng cách histogram cao độ so với tập train (càng thấp càng tự nhiên).

B · CHI PHÍ TÍNH TOÁN

Params (triệu)

Kích thước mô hình.

Epoch time (giây)

Thời gian huấn luyện cho một epoch

Peak VRAM / Infer time



Mức sử dụng VRAM cực đại và thời gian sinh một bản nhạc.

NGUYÊN TẮC “CÔNG BẰNG”

- ① Cùng bộ dữ liệu tiền xử lý
- ② Cùng **tập train/validation**
- ③ Cùng bộ **20 prompt** đánh giá
- ④ Đánh giá tại cùng các mốc checkpoint (epoch **1, 5 và 10**)
- ⑤ Sử dụng cùng chương trình đánh giá

Loss qua 30 epoch

Bên trái: Transformer bắt đầu overfitting từ epoch 15. Bên phải: Diffusion hội tụ ổn định.



★ NHẬN XÉT

Transformer: Validation loss đạt mức thấp nhất tại epoch 15 (CE = 1.956), sau đó tăng dần (overfitting). Diffusion: MSE giảm qua từng epoch, đạt 0.00183 vào epoch 30.

So sánh kết quả giữa hai mô hình

Tóm tắt kết quả so sánh dựa trên các chỉ số đánh giá và đặc điểm của hai mô hình.

Tiêu chí so sánh	Music Transformer	Diffusion Model
Chất lượng giai điệu	Rất tốt - giai điệu mạch lạc, tự nhiên	Khá - giai điệu ngắn rõ ràng, ổn định
Bám prompt (mood/instrument)	Khá	Tốt - nhờ CFG (guidance scale)
Sinh nhạc dài	Tốt - sinh ra bản nhạc dài, tự nhiên	Bị giới hạn bởi kích thước roll (~10s)
Thời gian sinh 1 bản	Chậm hơn - sinh tuần tự từng token	Nhanh hơn - khử nhiễu song song
Số tham số	~7–8 triệu	Quy mô tương đương
VRAM khi train	Yêu cầu VRAM thấp hơn (bs=8)	Yêu cầu VRAM cao hơn (roll 2D, bs=2 - 4)
Điều khiển đa dạng	Điều khiển thông qua Cross-Attention	Điều chỉnh bằng CFG scale

ĐIỂM MẠNH TRANSFORMER

Ưu điểm: Giai điệu mạch lạc, hỗ trợ sinh nhạc dài, cần ít VRAM hơn

Phù hợp: Nhạc nền (BGM) hoặc các bản nhạc có cấu trúc dài.

ĐIỂM MẠNH DIFFUSION

Ưu điểm: Tuân theo prompt tốt, tốc độ sinh nhanh.

Phù hợp: Jingle, loop hoặc các đoạn nhạc ngắn.

Tổng kết & hướng phát triển

*Không có mô hình nào vượt trội ở mọi tiêu chí.
Mỗi mô hình phù hợp với những bài toán khác
nhau.*



Tóm tắt

01 Mỗi mô hình có thể mạnh riêng

Transformer có giai điệu mạch lạc; Diffusion tuân thủ *prompt* tốt.
Lựa chọn mô hình dựa trên mục tiêu ứng dụng cụ thể.

02 Quy trình đánh giá

Cùng bộ dữ liệu 14k MIDI + 6 thuộc tính chuẩn
+ split cố định 9:1 + 20 prompt đánh giá cố định

03 Có thể huấn luyện trên GPU phổ thông

Không cần hạ tầng GPU chuyên dụng; RTX 4060 hoặc RTX 5060 Ti
là đủ cho cả hai họ mô hình sinh nhạc ở mức nghe được.

HƯỚNG PHÁT TRIỂN

- **Latent Diffusion:** Áp dụng Latent Diffusion để giảm chi phí tính toán.
- **Text encoder** (BERT / T5): Sử dụng text encoder hỗ trợ prompt ngôn ngữ tự nhiên.
- **Multi-instrument channels:** Mở rộng sang sinh nhạc đa nhạc cụ.
- **Đánh giá chủ quan:** Thêm đánh giá chủ quan thông qua khảo sát người dùng và chuyên gia